

Project2: CIFAR-10 图像分类与批归一化

姓名：刘宇轩 学号：23300180016

2026 年 6 月 14 日

代码仓库: <https://github.com/sao-hui/DL-PJ2>

1 引言

本报告旨在完成课程第二个项目：在 CIFAR-10 数据集上训练并优化神经网络，以及深入研究 Batch Normalization 对优化过程的影响。基于 VGG-A 架构，逐一实现了全连接层、卷积层、池化层、激活函数等必备组件，并对比了不同滤波器数量、不同损失函数、不同激活函数以及不同优化器的性能。同时，构建了带 BN 的 VGG-A 模型，系统比较了其与无 BN 模型在训练曲线和损失景观上的差异。实验表明：BN 显著加速收敛、提高准确率，并使得损失景观更加平滑；综合最优配置（BN + LeakyReLU + 标签平滑 + Adam）在测试集上达到了 78.54% 的准确率。本文详细记录了实验设计、结果分析和主要发现。

2 实验设置

使用 PyTorch 内置的 CIFAR-10 数据集，包含 50000 张训练图像和 10000 张测试图像。预处理包括：

- 转换为张量 (ToTensor)
- 归一化：均值为 0.5，标准差为 0.5（将像素值从 $[0,1]$ 映射到 $[-1,1]$ ）

除非特别说明，各实验采用统一超参数：

- Batch size: 128
- 初始学习率: 0.001 (Adam) 或 0.01 (SGD)
- Epochs: 20
- 随机种子: 2020

- 优化器: Adam (对比实验中额外使用 SGD with momentum=0.9)
- 损失函数: 交叉熵 (对比实验中额外使用标签平滑 0.1)

3 第一部分: CIFAR-10 分类性能优化

3.1 不同滤波器数量的影响

为研究滤波器数量对性能的影响,我们对比了标准 VGG-A (通道数 $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$) 与轻量版 VGG-A_Light (通道数 $16 \rightarrow 32$, 且只保留两个卷积阶段)。结果如图 1 所示。




图 1: 不同滤波器数量的训练损失与验证准确率对比

分析: 标准模型参数量更大, 验证准确率最终达到约 75%, 而轻量模型准确率仅不到 70%。这表明在 CIFAR-10 上, 足够的滤波器数量对于提取有效特征是必要的, 但更多的滤波器也会增加过拟合风险。

3.2 不同损失函数的对比

我们比较了标准交叉熵(CrossEntropyLoss)与标签平滑交叉熵(label_smoothing=0.1)。结果如图 2。




图 2: 不同损失函数的训练损失与验证准确率对比

分析: 标签平滑使得训练损失略高于标准交叉熵, 但验证准确率略有提升, 表明标签平滑起到了正则化作用, 减少了模型对训练标签的过度自信, 从而改善了泛化能力。

3.3 不同激活函数的对比

将 VGG-A 中的所有 ReLU 替换为 LeakyReLU (负斜率 0.01), 对比结果如图 3。




图 3: 不同激活函数的训练损失与验证准确率对比

分析: LeakyReLU 在训练初期收敛稍快, 最终损失与 ReLU 相近, 但准确比 ReLU 稍高。

3.4 不同优化器的对比

对比 Adam 与 SGD with momentum (0.9), 结果如图 4。




图 4: 不同优化器的训练损失与验证准确率对比

分析：Adam 收敛速度极快，仅需 10 个 epoch 就达到约 74% 准确率，而 SGD 需要 20 个 epoch 才能接近，且尚未完全收敛。在最佳模型选择中，我们依据实测结果采用了 Adam，因为它在有限 epoch 内表现更佳。

3.5 最佳模型构建与性能

综合上述对比实验，我们选出以下最佳配置：

- 网络结构：VGG-A + BN + LeakyReLU
- 损失函数：交叉熵 + 标签平滑 (0.1)
- 优化器：Adam (lr=0.001)
- 训练 20 个 epoch

重新训练该模型，得到的训练曲线如图 5，测试准确率为 **81.91%**。参数量 9.75M，训练耗时 424 秒。




图 5: 最佳模型训练损失与验证准确率曲线

4 第二部分：批归一化研究

4.1 带 BN 与不带 BN 的训练对比

我们实现了 VGG-A_BatchNorm 类，在每一个卷积层后、ReLU 之前添加了 BN 层。对比训练结果如图 6。




图 6: 有无 BN 的训练损失与验证准确率对比

分析：

- 带 BN 的模型损失下降速度更快。
- 验证准确率方面，BN 模型最终达到 81%，而无 BN 模型约 78%，提升显著。

4.2 损失景观分析

为了探究 BN 为何有助于优化，我们使用多个不同的学习率 ($1e-4$, $1e-3$, $2e-3$, $5e-4$) 分别训练带 BN 和不带 BN 的模型，记录每个训练 step 的损失值，并绘制损失变化范围（填充区域）。结果如图 7。




图 7: 有无 BN 的损失景观对比（不同学习率下的损失变化范围）

分析:

- 无 BN 的模型（左图）填充带非常宽，说明损失对学习率变化极为敏感
- 加入 BN 后（右图），填充带显著收窄，所有学习率下的损失曲线都平滑下降，说明 BN 使得损失景观变得更加平滑。这一结果表明 BN 可以通过平滑损失景观来帮助优化。

5 结论

本项目在 CIFAR-10 上系统研究了神经网络优化策略以及批归一化的作用。主要结论如下：

1. 足够的滤波器数量、标签平滑、LeakyReLU 均能轻微提升模型性能，但最关键的提升来自批归一化。
2. 通过损失景观可视化，我们证实 BN 使得损失曲面更加平滑，从而允许使用更大的学习率并加速收敛。
3. 综合最佳模型（BN + LeakyReLU + 标签平滑 + Adam）在测试集上达到 81.92% 的准确率，且已充分验证各项优化策略的有效性。